

Jak se počítají bayesiánské modely

Aleš Vomáčka

Jak se počítají bayesiánské modely

Analytický přístup

- ▶ Klasický přístup jsme si už ukázali, skrze bayesův teorém.

$$P(Hypotza|Data) = \frac{P(Data|Hypotza) * P(Hypotza)}{P(Data)}$$

Analytický přístup

- ▶ Výhoda - pokud funguje, výpočetně velmi rychlé (srovnatelné s maximum likelihood.)
- ▶ Nevýhoda - Výpočet $P(Data)$ vyžaduje integraci (resp. je integrál)
- ▶ Důvodem je nutnost standardizovat $P(Data|Hypotza) * P(Hypotza)$, aby šlo o platnou distribuční funkci

Analytický přístup

- ▶ Integrál $P(Data)$ je v praxi spočitatelný za dvou podmínek:
 - ▶ Pokud používáme tzv. konjugální priory
 - ▶ pokud model samotný není moc složitý (tzn. nejde o multilevel nebo aditivní model apod.)

Konjugální priory

- ▶ Konjugální prior je takový prior, který má rozdělení ze stejné rodiny jako posterior
- ▶ Např. Pokud má náš prior i naše likelihood normální rozdělení, potom bude mít i posterior normální rozdělení.

Konjugální priory

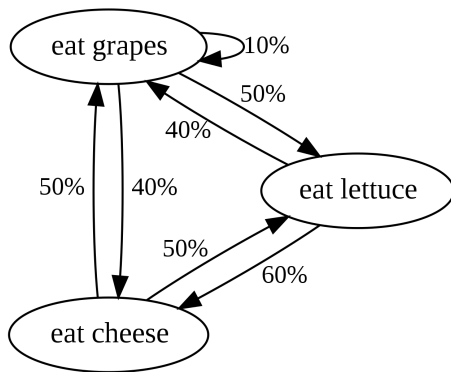
- ▶ V praxi jsme tedy omezení na specifické priory:
 - ▶ Normální prior pro klasickou lineární regresi
 - ▶ Beta prior pro logistickou regresi
- ▶ Často ale chceme vybírat priory na základě teorie bez omezení + konjugální priory neřeší problém s výpočtem složitých modelů.

Markov chain Monte Carlo

- ▶ Pokud se nedají bayesiánské modely počítat analyticky, dají se aproximovat simulačně
- ▶ Technika na výpočet bayesiánských modelů se nazývá Markov Chain Monte Carlo

Markov chain

- ▶ Sekvence stavů, kdy následující stav závisí pouze na tom stávajícím, ale ne na těch předchozích



Monte Carlo

- ▶ Pouze fancy název pro techniku simulace dat.
- ▶ Monte Carlo původně krycí název pro simulační techniky využité pro konstrukci atomové bomby.
- ▶ Dnes běžně využíváme např. u funkci `rnorm()`, `rbinom()` apod.

Markov Chain Monte Carlo

- ▶ Kombinací těchto dvou technik můžeme tahat vzorky z posteriorní distribuce, aniž bychom museli počítat $P(Data)$.
- ▶ Likelihood parametrů, které odhadujeme je vlastně prostor, kterým “cvrnkáme” fyzikální částici.
- ▶ Částici pravidelně zastavíme, zapíšeme si její pozici a vypustíme znovu.
- ▶ Místa, kde se částice zastaví jsou vzorky z posteriu, s dostatkem vzorků dostaneme dobrou představu o tvaru posterioru

Markov Chain Monte Carlo


- ▶ Stan (jazyk, který používáme pro výpočet modelů) využívá Hamiltonské MCMC
- ▶ Grafické vysvětlení [zde](#)

Markov Chain Monte Carlo


- ▶ Konceptuální znalost MCMC je důležitá:
 - ▶ Abyste chápali, proč je výpočet bayesiánských modelů tak pomalý (ve srovnání s MLE)
 - ▶ Abyste věděli, jak interpretovat diagnostické grafy.

R InteRmezzo

Špatná konvergence



Špatná konvergence



Divergentní tranzice

